Datathon Contest – Phân tích dữ liệu kinh doanh thời trang

Khoa Duc Anh Lam
HCMUT – VNUHCM
khoa.lamgeo07@hcmut.edu.vn

Minh Khoi Tran
HCMUT – VNUHCM
khoi.tran842007@hcmut.edu.vn

Son Phuc Pham
UIT – VNUHCM
25521438@gm.uit.edu.vn

Tuong Ngoc Cat Tran
UIT – VNUHCM
25522035@gm.uit.edu.vn

Abstract

Báo cáo phân tích hoạt động kinh doanh của doanh nghiệp thời trang thương mại điện tử Việt Nam qua bộ dữ liệu 15 file CSV (2012–2022), bao gồm hai bài toán chính: (1) Phân tích khám phá (EDA) về hành vi khách hàng và hiệu quả khuyến mãi, và (2) Dự báo doanh thu giai đoạn 2023–2024 bằng LightGBM với dự báo đệ quy. Mô hình đạt R^2=0,80 trên tập holdout 2022. Kết quả cung cấp cơ sở giúp tối ưu chiến lược kinh doanh và quản lý tồn kho.

1 Dữ liệu và Phương pháp luận

Tổng quan bộ dữ liệu. Bộ dữ liệu huấn luyện gồm 3.833 bản ghi doanh thu hàng ngày (04/07/2012–31/12/2022). Tập kiểm tra gồm dữ liệu từ 01/01/2023 đến 01/07/2024, dùng để đánh giá trên Kaggle.

Bảng 1: Cấu trúc bộ dữ liệu Datathon 2026.

Lớp	File	Biến chính
Master	products, customers, promotions, geography	product_id, price, cogs, segment, age_group, zip
Transaction	orders, order_items, payments, shipments, returns, reviews	order_id, unit_price, discount_amount, return_reason, rating
Analytical	sales.csv (train), sample_submission.csv (test)	Date, Revenue, COGS (hàng ngày)
Operational	inventory, web_traffic	sessions, conversion_rate, stockout_flag, fill_rate

2 Descriptive Analysis

Phân phối doanh thu theo sản phẩm. Trong top 8 sản phẩm dẫn đầu, hệ sinh thái SaigonFlex chiếm ưu thế áp đảo khi góp mặt tới 7/8 vị trí. Đáng chú ý, SaigonFlex UM-92 đứng đầu với doanh thu đạt 398.213.557 VND, vượt sản phẩm xếp thứ hai là HanoiStreet UM-10 (342.264.988 VND) khoảng 16,3%. Xét theo phân khúc, Activewear chiếm tỷ trọng lớn nhất với 24,8%, tiếp theo là Everyday (16,8%) và Performance (14,4%). Như vậy, chỉ riêng ba phân khúc này đã đóng góp hơn 56% tổng danh mục, cho thấy mức độ tập trung khá cao vào các dòng sản phẩm chủ lực.

39th Conference on Neural Information Processing Systems (NeurIPS 2025).

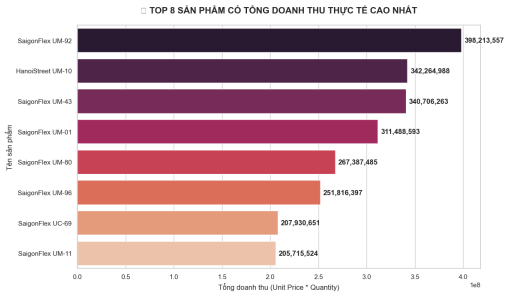

Hình 1: Top 8 sản phẩm có tổng doanh thu cao nhất.

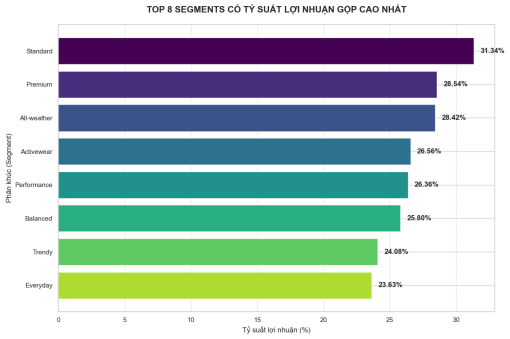

Hình 2: Top 8 phân khúc có tỷ suất lợi nhuận gộp cao nhất.

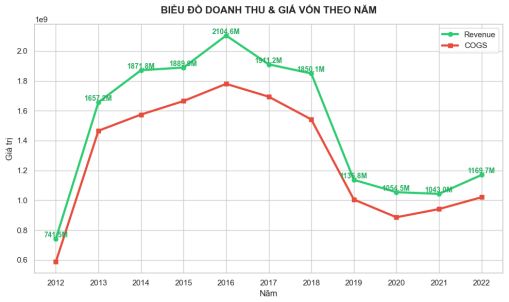

Hình 3: Xu hướng doanh thu & giá vốn 2012–2022.

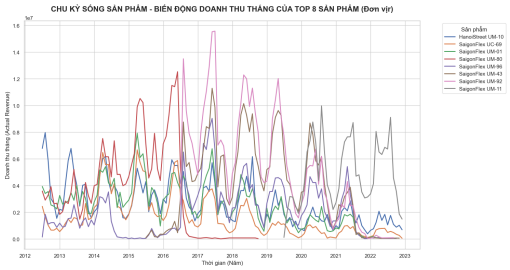

Hình 4: Chu kỳ sống – Top 8 sản phẩm theo thời gian.

Xu hướng doanh thu và giá vốn (2012–2022). Trong giai đoạn 2012–2022, doanh thu và COGS biến động gần như song hành và thể hiện xu hướng tương đồng rõ rệt. Cả hai chỉ số đều tăng mạnh từ mức 741,6M (2012) và đạt đỉnh vào năm 2016 (doanh thu khoảng 2.104,6M), sau đó cùng suy giảm và dần ổn định, dao động quanh ngưỡng 1.000–1.200M. Mô hình biến động tương tự này cho thấy mối quan hệ chặt chẽ giữa doanh thu và giá vốn qua các năm.

3 Diagnostic & Prescriptive Analysis

3.1 Phân tích Lý do Trả hàng

Biểu đồ lý do trả hàng kết hợp phân tích từ khóa review tiêu cực (nhóm 25–44 tuổi, rating ≤ 3) cho thấy ba vấn đề cốt lõi:

Sai kích cỡ (35%). *wrong_size* là lý do hàng đầu. Từ khóa *issues* xuất hiện 1.711 lần trong review tiêu cực, cho thấy bảng hướng dẫn size trên hệ thống chưa chuẩn hoặc mô tả form dáng gây nhầm lẫn – đây là nguồn chi phí logistics ngược chiều lớn nhất.

''Reality Gap'' (17,6%). *not_as_described* kết hợp với cụm từ *below expectations* tần suất cao phản ánh khoảng cách giữa hình ảnh quảng cáo và thực tế. Khách không phàn nàn mạnh nhưng cảm thấy bị lừa, dẫn đến *changed_mind* (17,4%) – tổng hai lý do này chiếm 35% đơn trả.

Chất lượng tầm thường (20,1%). Cứ 5 đơn trả thì 1 đơn lỗi kỹ thuật (*defective*). Kết hợp từ khóa *poor, average, nothing special* cho thấy sản phẩm không chỉ lỗi mà còn thiếu giá trị cảm nhận – dễ bị thay thế bởi đối thủ.

3.2 Phân khúc Khách hàng – RFM

Mô hình RFM chấm điểm 1–5 theo Quintile cho ba chiều Recency, Frequency, Monetary, tạo mã tổng hợp RFM $= R\times100 + F\times10 + M$. Quy tắc phân khúc:

Phân khúc	Điều kiện	Hành động
Champions	$R\geq4, F\geq4$	VIP, upsell, ambassador
Loyal Customers	$R\geq3, F\geq3$	Loyalty reward, cross-sell
Potential Loyalists	$R\geq3, M\geq3$	Nudge tần suất, bundle offer
At Risk	$R\leq2, F\geq3$	Win-back campaign, khảo sát
Cant Lose Them	$R\leq2, F\geq4, M\geq4$	Ưu đãi khẩn cấp, gọi điện
Lost	$R\leq2, F\leq2$	Đánh giá ROI tái kích hoạt

Insight địa lý. Top 5 thành phố tập trung nhiều nhất khách thuộc nhóm *Champions* + *Loyal* + *Potential* – đây là vùng ưu tiên triển khai chương trình loyalty và phân bổ tồn kho cao cấp. Ngược lại, nhóm *At Risk* + *Lost* phân bổ rải rác hơn, phù hợp với chiến dịch email/push notification tự động thay vì offline.

3.3 Cohort Retention

Định nghĩa. Cohort là nhóm khách hàng có cùng tháng mua đầu tiên. Tỷ lệ retention tháng N của cohort t:

$$\text{Retention}_{t,N} = \frac{|\text{KH cohort } t \text{ mua lại ở tháng } t+N|}{|\text{KH cohort } t|} \times 100\%$$

Phát hiện chính.

- Hầu hết các cohort đều có tỉ lệ khách ràng rời đi rất cao, nghĩa là mất đi gần 90% sau tháng đầu tiên, có thể đến từ chất lượng sản phẩm cũng như chính sách quảng bá thương hiệu
- Các cohort 2012–2016 có retention tháng 1 ổn định hơn hẳn so với giai đoạn 2017–2022, minh chứng cho sự tích lũy của hiện tượng ''hidden dissatisfaction'' sau năm 2016.
- Các khách hàng mới sụt giảm mạnh và không ổn định cho thấy quy mô kinh doanh đang giảm xuống rõ rệt

3.4 Chiến lược tối ưu hóa

(1) Cải thiện thông tin sản phẩm: Chuẩn hóa bản hướng dẫn, thông tin hình ảnh, sản phẩm trên mọi nền tảng, đồng thời đẩy mạnh các sản phẩm không bị lỗi thời và có lượt mua cao.

(2) Các chương trình ưu đãi: Tiến hành thực hiện các chương trình khuyến mãi kích cầu khách hàng, như voucher giảm giá, gửi email sau 2 tuần khách hàng mua sản phẩm, đặc biệt là các khách hàng đánh giá điểm rating cao

(3) Xây dựng chương trình retention: Tập trung vào nhóm *Potential Loyalists* và *Loyal Customers* theo địa lý Top 5 city. Đây là tệp có ROI cao nhất để đẩy tần suất mua lại.

(4) Phân khúc khách hàng: Tỉ lệ At Risk + Lost phân bố rải rác lớn, gây ảnh hưởng nghiêm trọng tới doanh thu. Do đó cần đẩy mạnh các chiến dịch marketing đến những khu vực này như email hay push notification tự động, quảng bá hình ảnh sản phẩm đó phù hợp với từng vùng, đặc biệt là các vùng cao để thể hiện rõ nét đẹp của sản phẩm.

(5) Cảnh báo sớm Khi retention giảm liên tiếp 2 quý trong khi rating ổn định — đó là tín hiệu cảnh báo - cần điều tra ở các khâu khác nhau để sớm tìm ra "lỗ hỏng"trong mô hình kinh doanh

4 Predictive Analysis – Dự báo doanh thu 2023–2024

4.1 Kỹ thuật trích xuất đặc trưng

Cả hai mục tiêu (`Revenue`, `COGS`) được biến đổi qua $\log(1+x)$ để ổn định phương sai. Chu kỳ năm được mã hoá liên tục bằng cặp Fourier:

$$\text{sin_year} = \sin\left(\frac{2\pi\cdot\text{doy}}{365{,}25}\right), \quad \text{cos_year} = \cos\left(\frac{2\pi\cdot\text{doy}}{365{,}25}\right)$$

Bảng 2: Tóm tắt kỹ thuật trích xuất đặc trưng.

Nhóm	**Đặc trưng**	**Lý do lựa chọn**
Lịch	`month, day, dow`	Mùa vụ theo tháng/tuần
Cờ nhị phân	`is_weekend, is_payday, is_double_date`	Ngày đặc biệt có pattern riêng
Ngoại sinh	`sessions`	Chỉ số dẫn đầu (corr = 0,32)
Fourier	`sin_year, cos_year`	Mã hoá chu kỳ năm mượt mà
Lag Revenue	`rev_lag_1,7,30`	Động lực ngắn/trung/dài hạn
Lag COGS	`cogs_lag_1,7`	Quan hệ Revenue–COGS

tránh gián đoạn đột ngột khi tháng 12 chuyển sang tháng 1 so với one-hot encoding.

4.2 Kiến trúc mô hình và dự báo đệ quy

Chúng tôi huấn luyện hai mô hình LightGBM độc lập cho log-Revenue và log-COGS (`learning_rate = 0,02`; `num_leaves = 31`; `feature_fraction = bagging_fraction = 0,8`; `early_stopping = 100`). Phân chia thời gian: train 2012–2021 (3.468 ngày), validation 2022 (365 ngày), test 2023–07/2024 (548 ngày).

Với horizon 18 tháng, đặc trưng lag được lấy từ dự báo trước (dự báo đệ quy):

$$\hat{y}_t = f\big(\text{lịch}_t,\ \text{sessions}_t,\ \hat{y}_{t-1},\ \hat{y}_{t-7},\ \hat{y}_{t-30}\big)$$

Đặc trưng Fourier cung cấp tín hiệu mùa vụ độc lập, giảm thiểu rủi ro tích luỹ sai số qua các bước lag.

4.3 Kết quả

Bảng 3: Hiệu suất validation (holdout năm 2022) và thống kê dự báo 2023–2024.

Validation		**Dự báo (trung bình/ngày)**	
Chỉ số	Giá trị	Chỉ tiêu	Giá trị (VND)
MAE	545.237 VND	Revenue	4.227.522
RMSE	750.223 VND	COGS	3.610.569
R^2	0,7991	Rev max	12.599.945
MAPE	19,35%	COGS max	10.868.792
Public Score (Kaggle): 864.556,19			

Mô hình giải thích ≈80% phương sai doanh thu hàng ngày. MAPE 19,35% phản ánh thách thức khi dự báo các ngày biến động cao (flash sale, khuyến mãi) – những ngày này chiếm tỷ trọng không cân xứng trong tổng sai số. Vòng dừng sớm tốt nhất: Revenue tại vòng 775, COGS tại vòng 712.

Hội tụ huấn luyện.

Vòng	**Train RMSE**	**Val RMSE**
200	0,1915	0,2598
400	0,1570	0,2534
600	0,1362	0,2519
775*	0,1226	0,2508

*Vòng tốt nhất (dừng sớm)

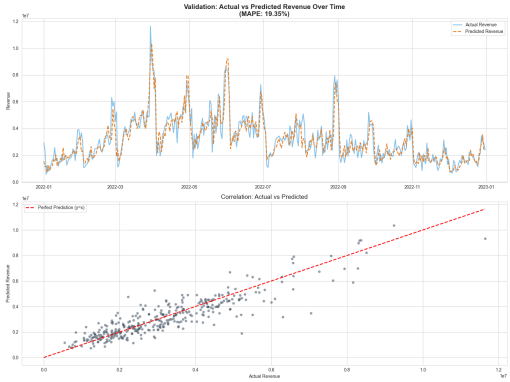

Hình 5: Validation 2022: Giá trị thực tế và dự đoán ở năm 2022

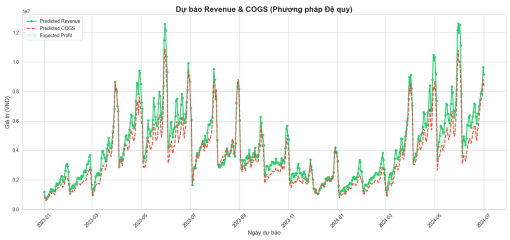

Hình 6: Dự đoán Revenue và Cogs ở 2 năm 2023 - 2024

5 Kết luận

Báo cáo phân tích toàn diện hoạt động kinh doanh của doanh nghiệp thời trang thương mại điện tử giai đoạn 2012–2022 theo ba trục chính.

Về hiệu suất kinh doanh, doanh nghiệp tăng trưởng mạnh đến 2016 nhờ acquisition tốt, nhưng suy giảm 50,4% sau đó do tích luỹ bất mãn ngầm – không phải vì sản phẩm tệ mà vì không đủ khác biệt để giữ chân khách. Rating ổn định nhưng retention giảm là tín hiệu cảnh báo sớm quan trọng cần theo dõi liên tục.

Về trải nghiệm khách hàng, ba vấn đề cốt lõi – sai kích cỡ (35%), mô tả sản phẩm không trung thực (17,6%) và chất lượng tầm thường (20,1%) – đang cộng hưởng làm tăng chi phí logistics ngược và xói mòn lòng tin. Phân tích RFM cho thấy nhóm *At Risk* và *Cant Lose Them* cần can thiệp ngay; cohort retention chỉ ra cửa sổ hành động tối ưu là tháng 30–120 sau lần mua đầu.

Về dự báo, mô hình LightGBM đệ quy đạt R^2=0,80 trên holdout 2022 với MAPE 19,35%. Hạn chế chính là tích luỹ sai số qua các bước lag và độ nhạy cao với các ngày flash sale

Tài liệu

[1] What is RFM Analysis? Calculating RFM Score for Customer Segmentation https://clevertap.com/blog/rfm-analysis/